

Examensarbete

Strukturering och kontextualisering av heterogent digitalt material för LLM-baserad analys: design och utvärdering av ett transformationslager hos Bonnier News.

Ange eventuell titel på engelska här

Ange eventuell undertitel på engelska här.

Författare:

Joakim Wikman.

Joakim Sandström

Nivå: Grundnivå

Kursnamn: Thesis for Bachelor degree in Informatics.

Kurskod: GIK28T

Högskolepoäng: 15hp

Handledare: Johan Håkansson

Institution: Institutionen för information och teknik

Examinator: Joonas Päckönen

Examinationsdatum: 2026-05-27

Vid Högskolan Dalarna finns möjlighet att publicera examensarbetet i fulltext i DiVA. Publiceringen sker Open Access, vilket innebär att arbetet blir fritt tillgängligt att läsa och ladda ned på nätet. Därmed ökar spridningen och synligheten av examensarbetet.

Open Access är på väg att bli norm för att sprida vetenskaplig information på nätet. Högskolan Dalarna rekommenderar såväl forskare som studenter att publicera sina arbeten Open Access.

Jag/vi medger publicering i fulltext (öppet tillgänglig på nätet, Open Access):

Ja ☒

Nej ☐

Innehållsförteckning

Abstract

Keywords

Sammanfattning

1. Inledning	1
1.1. Bakgrund.....	1
1.2. Problembeskrivning	1
1.3. Syftesmotivering	2
2. Syfte.....	4
2.1. Forskningsfrågor	4
3. Avgränsningar.....	4
4. Teoretisk referensram	5
4.1. Inledning	5
4.2. Begreppsdefinitioner.....	6
4.3. Utmaningar med stora databaser och LLM:er	7
4.4. Retrieval-Augmented Generation (RAG)	7
4.5. Kunskapsgrafer och grafbaserade databaser	8
4.6. Grafbaserad RAG.....	8
4.7. Grafbaserad retrieval kontra vektorbaserad retrieval.....	9
4.8. Begränsningar i grafbaserad RAG	10
4.9. Informationskvalitet	11
4.10. Teoretiska implikationer för artefaktdesign och utvärdering.....	11
5. Metod	12
5.1. Forskningsstrategi	12
5.2. Datainsamling och datamaterial.....	13
5.3. Design och implementering av artefakt	13
5.4. Etablering av baseline	14
5.5 Utvärderingsdesign.....	15
5.6 Operationalisering av utvärderingsmått.....	15
5.7 Ground truth och analysmetod.....	16
5.8 Genomförande	17
5.9 Metoddiskussion	17

6. Systemdesign	19
6.1. Designgrund och mål	19
6.2. Artefaktens avgränsning	20
6.3. Systemstruktur	21
6.3.1. Datainput	22
6.3.2. Transformationslager	23
6.3.3. Output till språkmodell.....	24
6.3.4. LLM-baserad analys.....	24
6.4. Designbeslut.....	24
6.5. Koppling till utvärderingen.....	26
7. Resultat	27
7.1 Översikt över genomförda tester	27
7.2 Svarskorrekthet.....	28
7.3 Retrieval och svarsprecision.....	28
7.4 Hallucinationsfrekvens	29
7.5 Effektivitet och spårbarhet.....	29
7.6 Sammanfattning av resultat	30
8. Analys/Diskussion	31
8.1. Inledning	31
8.2. Designens svar på RQ1	31
8.3. Tolkning av resultaten i förhållande till RQ2	31
8.4. Effektivitet, avvägningar och spårbarhet	32
8.5. Resultaten i förhållande till tidigare forskning	33
8.6. Begränsningar i tolkningen	33
9. Slutsats	34
Referenser	
Bilagor	

Abstract

Kort sammanfattning av examensarbetet på engelska.

Brödtexten ska skrivas i Times New Roman, 12 punkter. Radavstånd ska vara Flera 1,25 rader. Inget avstånd före och efter.

After the first page, we/I have written a summary / abstract of max 300 words, which contains a brief background, research questions and / or purpose, method and conclusion

If your report is in Swedish, the title and abstract/summary are also written in English, and vice versa, i.e. a report written in English must have a summary in Swedish, "Sammanfattning"

Keywords

RAG;hallucinationer;LLM;

Sammanfattning

Sammanfattning av uppsatsen.

1. Inledning

1.1. Bakgrund

Bonnier News är en av Nordens största mediekoncerner och hanterar dagligen stora mängder information i form av artiklar, journalistuppgifter, ämnesklassificeringar och händelsedata. Informationen lagras i flera olika databassystem och format, där data kan vara strukturerad på varierande sätt och innehålla komplexa relationer mellan exempelvis artiklar, personer, ämnen och publiceringssammanhang. Detta försvårar kontextbevarande analys eftersom relationer mellan informationsobjekt riskerar att gå förlorade när data hämtas från flera system.

I den genomförda implementationen används benchmarkkorporus HERB (Salesforce), som innehåller strukturerad företagsinformation: produktokument, Slack-trådar, pull requests, mötestranskript och fråge-svar-par. Studien är därmed metodiskt inriktad på heterogen strukturerad JSON och en grafrepresentation i Neo4j, medan samarbetet med Bonnier News motiverar krav på spårbarhet och kontrollerad informationshämtning i en redaktionell kontext. Exempel i senare kapitel som rör produkter, medarbetar-ID och kanaler ska läsas mot HERB, inte mot en specifik Bonnier-datamodell.

Syftet med denna studie är därför inte att utveckla en lösning anpassad till en specifik databasstruktur eller datamodell, utan att undersöka en generell metod för effektiv LLM-baserad analys oberoende av hur data är organiserad. Fokus ligger på hur grafbaserad RAG kan användas för att representera och tillgängliggöra relationer i data på ett flexibelt sätt, så att språkmodellen kan arbeta med olika informationskällor utan krav på en särskild underliggande struktur.

Samtidigt har stora språkmodeller (LLM:er) skapat nya möjligheter inom textanalys och informationsutvinning (Sun et al., 2025). Användningen av naturligt språk för att analysera och interagera med stora datamängder har därmed blivit mer tillgänglig, men modellernas effektivitet är starkt beroende av hur information representeras, organiseras och görs åtkomlig (Chen et al., 2025; Sun et al., 2025). Projektet genomförs i samarbete med Bonnier News och undersöker hur grafbaserad RAG kan användas för att skapa och utnyttja relationer mellan data vid LLM-baserad analys.

1.2. Problembeskrivning

När stora och heterogena datamängder används som underlag för LLM-baserad analys uppstår flera utmaningar kopplade till informationsutvinning och

kontexthantering. Traditionella metoder för datahämtning, exempelvis SQL-frågor eller nyckelordsbaserade sökningar, returnerar ofta information i ett platt format där relationer mellan dataobjekt går förlorade. Därmed riskerar viktiga semantiska samband mellan exempelvis artiklar, personer, ämnen och händelser att inte bevaras, vilket kan försämra språkmodellens förmåga att förstå sammanhang och öka risken för felaktiga eller fabricerade svar, så kallade hallucinationer. Tidigare forskning visar att hur information representeras och görs tillgänglig har stor betydelse för LLM:ers tillförlitlighet och prestanda (Chen et al., 2025; Huang et al., 2025; Lin et al., 2024).

Problemet blir särskilt tydligt i miljöer där information lagras i flera olika databassystem och format med varierande strukturer och relationer. När data hämtas med konventionella metoder riskerar relationerna mellan olika informationsobjekt att försvinna eller förenklas, vilket begränsar möjligheten att genomföra effektiv och kontextmedveten analys med hjälp av LLM:er. En möjlig lösning är grafbaserad RAG (Retrieval-Augmented Generation), där relationer mellan data representeras som en grafstruktur. En sådan ansats kan göra det möjligt att bevara och utnyttja semantiska samband mellan olika informationsobjekt, vilket i sin tur kan bidra till mer precisa och kontextuellt relevanta svar från språkmodellen. Det finns därför ett behov av att undersöka hur grafbaserad RAG kan användas som en generell metod för att stödja LLM-baserad analys oberoende av hur den underliggande datan är organiserad eller lagrad.

Trots ett växande forskningsintresse för RAG och kunskapsgrafer finns flera kunskapsluckor inom området. Många GraphRAG-studier, exempelvis Edge et al. (2024), fokuserar främst på ostrukturerade textsamlingar där grafen konstrueras i efterhand, snarare än på data som redan är lagrad i relationella databaser eller dokumentdatabaser. Vidare genomförs jämförelser mellan grafbaserad och vektorbaserad retrieval huvudsakligen på generella utvärderingsdataset för frågesvarssystem och sällan i miljöer där data innehåller komplexa och varierande relationsmönster mellan olika typer av informationsobjekt. De implementationer som genomförs inom ramen för Design Science Research fokuserar dessutom ofta på teknisk genomförbarhet snarare än systematiska jämförelser mot etablerade baseline-lösningar. Dessa kunskapsluckor motiverar behovet av en designstudie som utvecklar och utvärderar en grafbaserad RAG-artefakt för LLM-baserad analys i heterogena datamiljöer.

1.3. Syftesmotivering

Mot bakgrund av de identifierade problemen finns ett behov av att undersöka hur heterogent digitalt material kan förberedas för att möjliggöra en mer tillförlitlig användning av stora språkmodeller. Genom att utveckla och utvärdera ett transformationslager kan denna studie bidra med kunskap om hur strukturering och kontextualisering av data påverkar LLM-baserad analys i praktiska tillämpningar.

2. Syfte

Syftet med studien är att utveckla och utvärdera en grafbaserad RAG-artefakt för att hämta, representera och kontextualisera information från heterogena databaser inför LLM-baserad analys. Fokus ligger på att undersöka hur grafbaserad retrieval påverkar kontextbevarande och svars kvalitet vid komplexa frågor som kräver samband mellan flera informationsobjekt, så kallade multi-hop-frågor, där traditionella retrieval metoder har identifierade begränsningar.

Utvärderingen genomförs som en kontrollerad jämförelse mellan den grafbaserade artefakten och en baseline lösning där data hämtas direkt från databaser och används som input till språkmodellen utan grafbaserad relationshantering.

2.1. Forskningsfrågor

RQ1: Hur kan ett grafbaserat RAG-system designas för att stödja kontextbevarande hämtning från strukturerade databaser i LLM-baserad analys?

RQ2: Vilken effekt har grafbaserad hämtning, jämfört med direkt databashämtning, på (a) svarskorrekthet, (b) retrieval och svarsprecision samt (c) hallucinationsfrekvens vid LLM-baserad analys.

3. Avgränsningar

För att göra studien genomförbar inom given tidsram görs följande avgränsningar:

Datakälla: Projektet avser inte att utveckla eller modifiera datainsamlingsverktyg.

Testdata och integritet: Utvärderingen genomförs på data som kan användas inom ramen för projektets praktiska och rättsliga förutsättningar. Detta innebär att datamaterialet vid behov kommer att avgränsas, anonymiseras eller på annat sätt anpassas för att möjliggöra en genomförbar och ansvarsfull utvärdering.

Val av språkmodell: Utvärderingen avgränsas till ett begränsat urval av språkmodeller som bedöms vara relevanta för den användningskontext som studien utgår från.

4. Teoretisk referensram

4.1. Inledning

Detta examensarbete befinner sig i skärningspunkten mellan stora språkmodeller (LLM:er), informationsutvinning och grafbaserad datahantering. Den teoretiska referensramen har två syften: att identifiera de mekanismer som gör direkt databashämtning otillräcklig som indata till LLM-baserad analys, samt att motivera varför grafbaserad RAG kan utgöra en lämplig lösning på dessa brister. Referensramen struktureras kring fyra områden som bygger på varandra: utmaningar med stora databaser och LLM:er, RAG som paradigm, kunskapsgrafer som representationsform, samt grafbaserad RAG. En femte del behandlar distinktionen mellan grafbaserad och vektorbaserad retrieval, vilken är avgörande för att motivera designvalet i studiens artefakt. Tidigare forskning indikerar att hallucinationer och kontextförlust vid naiv hämtning är ett återkommande problem, och att grafbaserade ansatser i flera studier har visat sig kunna reducera dessa brister i strukturerade datamiljöer. Studien tar dessa fynd som utgångspunkt, men avser inte att betrakta problemet som slutgiltigt löst.

Litteratursökningen genomfördes huvudsakligen via databastjänsten EBSCOhost, vilken ger tillgång till flera vetenskapliga databaser. Detta möjliggjorde en bred och effektiv sökning av peer-reviewed artiklar inom området. Sökningarna begränsades till vetenskapligt granskade artiklar (peer-reviewed), publicerade på engelska och inom ett relevant tidsintervall.

Kategori	Information
Sökperiod	20-31 Mars 2026
Söktjänst	EBSCOhost (inkl. Academic Search Complete m.fl.)
Sökoperatörer	AND, OR, citattecken (" ")
Söksträngar	1. LLM AND hallucination mitigation AND data quality 2. llm AND hallucination AND structured input 3. hallucination reduction AND preprocessing pipeline 4. LLM AND factual accuracy AND unstructured data
Inklusionskriterier	• Peer-reviewed artiklar • Publicerade 2020–2026 • Engelska • Relevanta för LLM, datakvalitet, prompt engineering

Exklusionskriterier	• Icke-vetenskapliga källor • Ej relevanta för LLM • Dubbletter
Identifierade källor	15st

4.2. Begreppsdefinitioner

Två begrepp är centrala för studien och behöver preciseras innan den teoretiska genomgången tar vid: hallucination och multi-hop reasoning. Båda används frekvent i RAG-litteraturen men med varierande innebörd, och det är därför nödvändigt att klargöra hur de operationaliseras i denna studie.

Hallucination. Med hallucination avses i denna studie modellutdata som inte kan verifieras mot den underliggande databasen som används som ground truth. Denna definition är i linje med Chakraborty et al. (2025) som föreslår en flexibel definition centrerad kring otrohet mot den kunskapskälla modellen har tillgång till, snarare än mot någon absolut sanning. Huang et al. (2025) skiljer i sin taxonomi mellan flera typer av hallucinationer; denna studie fokuserar på fyra kategorier som är direkt relevanta för en grafbaserad RAG-kontext: (1) fabricerade entiteter modellen nämner personer, artiklar eller ämnen som inte finns i databasen, (2) felaktiga relationer modellen kopplar samman entiteter på sätt som strider mot databasens kanter, (3) felaktiga attribut modellen tillskriver en existerande entitet egenskaper eller värden som inte stöds av databasen, samt (4) icke-grundade inferenser modellen drar slutsatser som varken stöds av eller motsägs av databasen, men som presenteras som om de vore det. Det är dessa fyra kategorier som mäts i hallucinationsfrekvensen i avsnitt 5.6.

Multi-hop reasoning. Med multi-hop reasoning avses i denna studie frågor vars korrekta besvarande kräver information från flera relaterade segment, filer eller produkter i datamaterialet. Ett exempel från HERB-korpusen är frågan ”Vilka medarbetare har bidragit till samma produktområde som en given medarbetare?”, som kräver att modellen kopplar samman information om produkter, medarbetar-ID och kommunikationsspråk över flera segment. Den implementerade graf-armen utför inte explicit grafraversal över flera hopp i Cypher; istället hanteras relationell komplexitet via taggmatchning, facet-vikter och eventuell lexikal fallback. Multi-hop diskuteras därmed som frågetyp snarare än som garanterad algoritmisk egenskap. Single-hop-frågor där svaret kan hämtas via ett enda segment inkluderas också i utvärderingen som kontrollvillkor.

4.3. Utmaningar med stora databaser och LLM:er

Stora språkmodeller har visat stor potential för informationsutvinning och analys, men deras användbarhet är starkt beroende av hur relevant kontext tillhandahålls vid frågebesvaringstillfället. När LLM:er används mot stora databaser uppstår utmaningar kring vilken information som ska hämtas, hur den ska representeras och hur relationer mellan datapunkter ska bevaras. Lewis et al. (2020) introducerade RAG som ett paradigm där LLM:er kompletteras med ett externt hämtningssteg så att modellen kan grunda sina svar i hämtad information snarare än enbart i parametrisk kunskap. Utan sådana hämtningsmekanismer ökar risken för s.k. hallucinationer, det vill säga modellutdata som framstår som rimligt men som är faktamässigt felaktigt eller saknar grund i den underliggande datakällan. I denna studie används begreppet hallucination med en specifik och avgränsad innebörd, som beskrivs närmare i avsnittet Begreppsdefinitioner nedan. Huang et al. (2025) presenterar en taxonomi över orsaker till hallucinationer och framhåller bland annat brister i input, kontext och informationsrepresentation som viktiga faktorer. Lin et al. (2024) visar på liknande sätt att hur information representeras och hämtas är avgörande för modellernas tillförlitlighet, särskilt i kontexttunga frågehanterings scenarier. Zhang och Zhang (2025) preciserar i en peer-reviewed översikt av hallucinationer i RAG-system att fel kan uppstå i flera distinkta delsteg datakälla, fråga, retriever och rangordning vilket motiverar att artefaktdesignen behandlar hämtningssteget som en avgränsad och utvärderingsbar komponent.

4.4. Retrieval-Augmented Generation (RAG)

RAG kombinerar en hämtningskomponent med en generativ LLM i ett tvåstegsflöde: hämtning av relevant kontext från en extern kunskapskälla, följt av generering av ett svar baserat på denna kontext. Gao et al. (2023) identifierar tre generationer av RAG-system och visar att avancerade RAG-varianter, inklusive grafbaserade, överpresterar naiva ansatser på flerhoppssfrågor; Peng et al. (2024) bekräftar och utvidgar denna bild i en peer-reviewed survey som specifikt fokuserar på grafbaserad RAG och dess komponenter. Edge et al. (2024) rapporterar i GraphRAG att ett grafbaserat hämtningssteg kan reducera hallucinationer och möjliggöra flerhoppssresonemang i situationer där vektordatabasbaserade RAG-system har strukturella begränsningar. Sammantaget pekar denna forskning på att grafbaserad RAG kan bevara semantiska relationer

och bidra till ökad tillförlitlighet i LLM-baserad analys av relationsrik databasdata, något som denna studie avser undersöka empiriskt.

4.5. Kunskapsgrafer och grafbaserade databaser

Kunskapsgrafer representerar information som noder (entiteter) och kanter (relationer) och används för att modellera komplexa samband mellan olika typer av data. Genom att explicit beskriva relationer mellan informationsobjekt möjliggör kunskapsgrafer en mer strukturerad och semantiskt rik representation än traditionella tabellbaserade modeller. Ji et al. (2022) beskriver hur kunskapsgrafer kan stödja inferens och avancerade frågor över sammanlänkad data på ett sätt som platta datamodeller har begränsningar att hantera. Grafdatabaser, exempelvis Neo4j, är utvecklade för att lagra och hantera denna typ av relationsbaserad information och erbjuder frågespråk som Cypher för att traversera relationer mellan noder. Sådana strukturer är särskilt relevanta i miljöer där data innehåller många sammanlänkade informationsobjekt och där relationerna mellan dessa är centrala för analysen. Forskning visar även att integrering av kunskapsgrafer med stora språkmodeller kan förbättra modellernas faktagrund och bidra till mer kontextuellt relevanta svar. Pan et al. (2024) argumenterar exempelvis för att kunskapsgrafer kan minska risken för hallucinationer genom att språkmodellen får tillgång till tydligare och mer strukturerade relationer mellan dataobjekt. Detta gör kunskapsgrafer relevanta i studier som undersöker hur LLM-baserad analys kan stödjas i heterogena datamiljöer med komplexa relationsstrukturer.

4.6. Grafbaserad RAG

Grafbaserad RAG kombinerar Retrieval-Augmented Generation (RAG) med kunskapsgrafer relationsbaserade representation av data. Till skillnad från traditionella RAG-system, som vanligtvis hämtar isolerade textsegment från en vektordatabas, använder grafbaserad RAG relationer mellan informationsobjekt för att navigera och hämta kontextuell information. Detta möjliggör att semantiska samband mellan olika dataobjekt bevaras under hämtningsprocessen. Edge et al. (2024) introducerade GraphRAG och visar att grafbaserad retrieval kan stödja mer komplex frågebesvaring där svar kräver syntes av information från flera källor. Författarna menar att traditionella vektorbaserade RAG-system har strukturella begränsningar i sådana scenarier eftersom relationerna mellan informationsobjekt inte representeras explicit. Genom att traversera noder och

relationer i en kunskapsgraf kan grafbaserad RAG i stället stödja så kallad multi-hop reasoning, där modellen stegvis kopplar samman information från flera relaterade datakällor.

Liknande resultat presenteras av Lan et al. (2021), som i en översikt över kunskapsgrafbaserad frågehantering visar att grafbaserade metoder är särskilt effektiva för komplexa frågor som kräver flera logiska kopplingar mellan informationsobjekt. Peng et al. (2024) lyfter dessutom fram två centrala fördelar med GraphRAG i LLM-baserad analys: möjligheten att bevara explicit relationskontext samt förbättrad spårbarhet mellan genererade svar och underliggande datakällor.

I denna studie används grafbaserad RAG som den övergripande designansatsen för att undersöka hur relationer mellan data kan representeras och utnyttjas vid LLM-baserad analys i heterogena datamiljöer. Fokus ligger följaktligen inte på en specifik databasmodell, utan på hur grafstrukturer kan användas för att skapa en mer generell och flexibel metod för kontextbevarande informationshämtning. Den metodologiska ramen för utveckling och utvärdering av artefakten baseras på Design Science Research och presenteras i avsnitt 5.1.

4.7. Grafbaserad retrieval kontra vektorbaserad retrieval

De två dominerande ansatserna för informationshämtning i RAG-system – vektorbaserad och grafbaserad retrieval skiljer sig grundläggande i hur information representeras och hämtas. Skillnaden är central för denna studie eftersom valet av retrievalmetod påverkar vilken kontext som görs tillgänglig för språkmodellen.

Vektorbaserad retrieval bygger på att text representeras som högdimensionella vektorer där semantiskt liknande texter placeras nära varandra i en vektorrymd. Relevansen mellan olika textsegment beräknas vanligtvis genom likhetsmått som kosinuslikhet. Metoden är effektiv när relevant information kan identifieras inom ett enskilt textavsnitt eller genom semantisk likhet mellan dokument. En begränsning är dock att semantiska samband mellan entiteter inte representeras explicit, utan reduceras till geometriska avstånd i vektorrummet. Detta innebär att komplexa samband mellan flera entiteter kan bli svåra att följa, särskilt vid multi-hop-frågor där flera relationssteg behöver kopplas samman i rätt ordning (Lan et al., 2021; Edge et al., 2024; Peng et al., 2024).

Grafbaserad retrieval utgår i stället från explicita relationer mellan noder och kanter i en kunskapsgraf. Genom att bevara relationerna mellan informationsobjekt möjliggör metoden traversal över flera sammanhängande steg,

vilket gör den särskilt relevant för frågor som kräver syntes av information från flera datakällor. Lan et al. (2021) visar att grafbaserade retrievalmetoder presterar bättre än textlikhetsbaserade ansatser vid komplexa multi-hop-frågor, medan Edge et al. (2024) demonstrerar att GraphRAG även kan hantera mer globala frågor där svar kräver sammanvägning av information från flera delar av datamängden. Samtidigt innebär grafbaserad retrieval vissa praktiska utmaningar. Metoden kräver att en grafstruktur konstrueras och underhålls, vilket generellt är mer resurskrävande än att indexera dokument som vektorer. Resultatet är dessutom beroende av hur väl relationer och entiteter modelleras i grafen, eftersom en ofullständig eller felaktig grafstruktur kan leda till att relevant kontext utelämnas. Trots dessa utmaningar erbjuder grafbaserad retrieval flera fördelar i miljöer där data innehåller många explicita och sammanlänkade relationer. Genom att representera relationer direkt i retrievalprocessen kan grafbaserade metoder bevara semantisk kontext på ett sätt som är svårt att uppnå med enbart vektorbaserad retrieval. Detta gör ansatsen särskilt relevant i studier som undersöker hur LLM-baserad analys kan förbättras i heterogena och relationsrika datamiljöer.

4.8. Begränsningar i grafbaserad RAG

Litteraturen lyfter samtidigt flera begränsningar med grafbaserad RAG som är relevanta för denna studie. En central utmaning är att metodens prestanda är starkt beroende av kvaliteten på den underliggande grafstrukturen. Om dessa kopplingar modelleras felaktigt eller om viktiga kopplingar saknas riskerar retrievalprocessen att missa relevant kontext eller generera missvisande samband, vilket kan påverka språkmodellens svar negativt (Peng et al., 2024).

En annan återkommande utmaning handlar om skalbarhet. Traversering i stora kunskapsgrafer med många noder och relationer kan vara resurskrävande och leda till högre svarstider jämfört med enklare retrievalmetoder. Edge et al. (2024) beskriver hur stora grafstrukturer ofta kräver optimeringar såsom indexering, partitionering och begränsningar i traverseringsdjup för att hålla latensen på en praktiskt användbar nivå.

Den grafbaserade ansatsen är dessutom beroende av att relevanta ingångsnoder identifieras korrekt utifrån användarens fråga. Om systemet misslyckas med att identifiera rätt entiteter eller relationer i frågan kan felaktiga traverseringar uppstå, vilket innebär att irrelevanta eller ofullständiga kontextkedjor skickas vidare till språkmodellen. Fel i de tidiga stegen av retrievalprocessen riskerar därmed att påverka hela analyskedjan.

Forskningen visar också att gränsen mellan grafbaserade och vektorbaserade retrievalmetoder i praktiken ofta är flytande. Många moderna GraphRAG-lösningar använder hybridansatser där embeddings används för att identifiera relevanta startpunkter i datan, medan grafstrukturen används för vidare traversal och relationsbaserad kontextutvinning (Peng et al., 2024). Detta innebär att grafbaserad retrieval inte nödvändigtvis ersätter vektorbaserade metoder, utan snarare kompletterar dem i situationer där relationer mellan informationsobjekt är centrala.

Dessa begränsningar utgör viktiga designöverväganden i studien och är relevanta vid både utveckling och utvärdering av den grafbaserade RAG-artefakten.

4.9. Informationskvalitet

Begreppet informationskvalitet är centralt för att förstå hur hämtad kontext påverkar resultatet av LLM-baserad analys. Tidigare forskning om LLM:er visar att kvaliteten på hämtad information dess relevans, fullständighet och relationsrikedom är avgörande faktorer för modellens prestation (Huang et al., 2025; Lin et al., 2024). I grafbaserade RAG-system är informationskvaliteten direkt kopplad till hur väl den hämtade subgrafen fångar den kontext som behövs för att besvara frågan.

Informationskvalitet kan beskrivas utifrån flera dimensioner, där några av de mest relevanta i denna studie är:

Noggrannhet (accuracy): i vilken utsträckning informationen är korrekt

Fullständighet (completeness): om relevant information saknas

Konsistens (consistency): om informationen är enhetlig

Relevans (relevance): om informationen är användbar för syftet

Ett grafbaserat RAG-system kan bidra till att förbättra dessa dimensioner genom att säkerställa att hämtad kontext är semantiskt relevant (precision), relationellt fullständig (fullständighet) och konsekvent representerad (konsistens).

Grafbaserad hämtning bevarar dessutom källkoppling till specifika databasnoder, vilket stödjer verifierbarhet och minskar hallucinationer (Edge et al., 2024; Huang et al., 2025).

4.10. Teoretiska implikationer för artefaktdesign och utvärdering

Utifrån den teoretiska referensramen kan ett antal centrala designimplikationer identifieras. Dessa fungerar som en brygga mellan tidigare forskning, artefaktens utformning och den efterföljande utvärderingen.

Teoretisk utgångspunkt	Implikation	I studien	Utvärdering
Heterogen data varierar i format, struktur och semantisk tydlighet.	Materialet behöver normaliseras.	Rådata omformas till strukturerad representation.	Rådata jämförs med processad data.
Brus och irrelevant kontext kan försämra LLM-output.	Irrelevant information behöver filtreras.	Filtrering används före LLM-input.	Felaktiga och irrelevanta svar jämförs.
LLM-output påverkas av hur information presenteras.	Input behöver kontextualiseras.	Metadata och strukturell kontext bevaras eller tillförs.	Korrekthet, precision och relevans bedöms.
Hallucinationer kopplas till svagt underlag.	Källkoppling behöver bevaras.	Processad input relateras till källa eller ground truth.	Påståenden jämförs med verifierat underlag.

5. Metod

5.1. Forskningsstrategi

Denna studie utgår från en **Design Science Research (DSR)**-ansats, vilken syftar till att utveckla och systematiskt utvärdera en artefakt som adresserar ett identifierat problem (Hevner et al., 2004; Peffers et al., 2007). DSR är särskilt lämplig i denna studie då fokus ligger på att förbättra hanteringen av heterogent datamaterial inför analys med stora språkmodeller (LLM), snarare än att enbart analysera ett fenomen.

Artefakten i denna studie utgörs av ett transformationslager som syftar till att strukturera, filtrera och kontextualisera data för att förbättra kvaliteten på LLM-baserad analys. Arbetet genomförs iterativt i enlighet med etablerade DSR-principer, där problemidentifiering, design, implementering och utvärdering sker i återkommande cykler (Peffers et al., 2007).

Denna ansats kombineras med ett **jämförande experimentellt inslag**, där artefaktens effekt utvärderas mot en baseline. Detta möjliggör en mer systematisk analys av artefaktens bidrag, vilket stärker studiens interna validitet.

5.2. Datainsamling och datamaterial

Datamaterialet utgörs av korpusen HERB (Salesforce__HERB), laddad till ett lokalt korpusarkiv och materialiserad i grafdatabasen Neo4j (databas herb). Varje payload-fil (produkt-JSON under products/, metadata under metadata/) upsertas som :File-noder och delas deterministiskt i :Chunk-segment med locator_json och fulltext i content. Den färdiga semantiska körningen identifieras med run_id = pilot_full_herb (~5843 segment i full körning enligt projektdokumentation). För utvärdering används en härledd databas herb-eval där fråge- och oracle-tyor (answerable_questions, unanswerable_questions, product_profile) exkluderas för att minska läckage. Datamaterialet innehåller informationsobjekt och relationer mellan dessa (produkter, medarbetare, Slack-kanaler, pull requests och dokument), vilket är representativt för moderna informationsmiljöer där data lagras i flera sammlänkade strukturer och format (Kitchin, 2014).

Urvalet av data genomförs strategiskt för att skapa variation i både informationsstruktur och relationsdjup, vilket är viktigt för att kunna utvärdera den grafbaserade RAG-artefaktens förmåga att hantera olika typer av retrievals scenarier. Enligt Yin (2018) är ett målstyrt urval lämpligt i studier där syftet är att undersöka ett fenomen i en komplex kontext. I denna studie innebär det att testfallen utformas för att inkludera både enklare frågor med direkta relationer och mer komplexa multi-hop-frågor som kräver traversal över flera relaterade informationsobjekt.

Datamaterialet används för att undersöka hur grafbaserad retrieval påverkar språkmodellens möjlighet att bevara kontext och identifiera relevanta samband mellan dataobjekt i heterogena datamiljöer. Fokus ligger därför på relationer och informationsstruktur snarare än på innehållet i en specifik datakälla eller domän.

5.3. Design och implementering av artefakt

Artefakten utformas som ett grafbaserat RAG-system med fokus på att möjliggöra relationsbaserad informationshämtning för LLM-baserad analys. Systemet består av tre centrala funktioner:

- **Strukturerings:** Data representeras som en kunskapsgraf där informationsobjekt modelleras som noder och relationer mellan dessa som kanter.
- **Grafbaserad retrieval:** Användarfrågor tolkas i två LLM-pass (frågebeskrivning, taggar, strukturell gate). Frågetaggar embeddas med samma modell som vid indexering och matchas via vektor-närmaste grannar mot tagg-vektorindex i Neo4j. Segment rankas därefter via viktade HAS_TAG-relationer kombinerat med relevance_to_file och gate-filter; vid utebliven träff finns en valfri lexikal fallback (fulltext). Hämtningen utför alltså inte explicit grafraversal över flera hopp, utan tagg-grundad poängsättning över HAS_TAG-kanter.
- **Kontextbearbetning:** Den hämtade grafkontexten filtreras, organiseras och serialiseras till ett format som kan användas som input till språkmodellen.

Designen utvecklas iterativt och baseras på identifierade begränsningar i traditionella retrievalmetoder. Detta ligger i linje med principerna inom Design Science Research (DSR), där artefakter successivt förbättras genom kontinuerlig utveckling och utvärdering (Hevner et al., 2004).

Artefakten avgränsas till en forskningsprototyp med fokus på kärnfunktionalitet snarare än en fullständig produktionslösning. En sådan avgränsning är vanlig i explorativa designstudier där syftet främst är att undersöka och utvärdera ett koncept eller en metod i en kontrollerad kontext (Peffers et al., 2007).

5.4. Etablering av baseline

För att möjliggöra jämförelse etableras en textuell baseline som avsiktligt inte använder tagggraf, frågetolkning eller strukturell gate. I den implementerade utvärderingskedjan (ragas-export) motsvarar baseline följande: användarfrågan skickas som ren text till Neo4j fulltext-index chunk_content_ft över Chunk.content (Lucene), med samma dataset-scope och samma sektions-exkluderingar som graph-armen (answerable_questions, unanswerable_questions, product_profile på herb-eval). Vid export används ett standard tak om 150 segment när ingen explicit limit anges, eftersom ocappad Lucene-sökning kan returnera tusentals träffar och överbelasta svar-API:et. Samma svarsmodell, promptläge och temperatur (0) används som i graph-armen. Detta fungerar som referenspunkt för att bedöma den grafberikade hämtningsvägens effekt.

I baseline-armen utför modellen samma typ av analysuppgifter som i den grafberikade armen, men kontextpaketet består enbart av fulltext-träffar på segmenttext. Uppgifterna kan exempelvis omfatta:

extraktion av nyckelinformation

sammanfattning av innehåll

identifiering av centrala entiteter

Att använda standardiserade testfall är en etablerad metod för att säkerställa jämförbarhet mellan olika experimentella scenarier (Kitchenham & Charters, 2007).

5.5 Utvärderingsdesign

Utvärderingen genomförs som en **kontrollerad jämförande studie** mellan två scenarier:

Scenario B (textbaseline): fråga → Lucene-fulltext på rå segmenttext (chunk_content_ft) → serialiserat kontextpaket → LLM-svar.

Scenario A (grafberikad): fråga → tolkning → taggrundning (e5 + kNN på taggvektorindex) → viktad HAS_TAG-retrieval under gate → serialiserat kontextpaket → LLM-svar.

För att säkerställa intern validitet hålls följande variabler konstanta:

identiska testfall

identiska promptar

samma språkmodell

Denna typ av kontroll är central inom experimentell metodik för att isolera effekten av den oberoende variabeln (artefakten) (Oates, 2006).

Varje test körs flera gånger för att reducera slumpmässig variation i modellens output, vilket är särskilt relevant vid arbete med probabilistiska system som LLM:er.

5.6 Operationalisering av utvärderingsmått

För att möjliggöra en systematisk analys operationaliseras centrala begrepp enligt följande:

Tillförlitlighet

Tillförlitlighet definieras som graden av korrekthet och konsistens i modellens output, och mäts genom:

andel korrekta svar i relation till en definierad ground truth

frekvens av hallucinationer

variation mellan upprepade körningar

Precision

Precision definieras som andelen korrekt identifierad relevant information i relation till totalt identifierad information:

Effektivitet

Som komplement analyseras även:

tokenförbrukning

svarslängd

bearbetningstid

Användningen av flera mått möjliggör en mer nyanserad utvärdering, vilket rekommenderas inom empirisk mjukvaruforskning (Kitchenham & Charters, 2007).

5.7 Ground truth och analysmetod

För att stödja en systematisk jämförelse mellan retrievalmetoder används en ground truth som hämtas från datasetets egna answerable_questions: fältet ground_truth i HERB:s qa_record-segment, extraherat med skriptet build_gold_set (read-only mot Neo4j). Detta är en auktoritativ dataset-etikett snarare än manuellt skriven av författarna från grunden, vilket gör definitionerna reproducerbara och oberoende av bedömarens tolkning. Ground truth-definitionerna föreligger därmed före experimentets genomförande och baseras på verifierbara relationer och fakta i datamaterialet. På så sätt undviks att bedömningen påverkas av språkmodellens genererade output.

För frågor med entydiga och faktabaserade svar kan ground truth verifieras objektivt mot den underliggande datan. För mer komplexa frågor som innehåller sammanfattande eller tolkande inslag används ett explicit bedömningskriterium: ett svar klassificeras som korrekt om det innehåller relevanta och verifierbara faktapåståenden utan att inkludera information som motsäger datakällan. Bedömningen dokumenteras löpande för att möjliggöra transparens och granskning av analysprocessen.

Analysen genomförs genom att:

jämföra språkmodellens output med definierad ground truth,

kvantifiera resultaten med mått såsom precision, recall och

hallucinationsfrekvens,

analysera skillnader mellan retrievalscenarierna och relatera dessa till artefaktens design och retrievalstrategi.

För att stärka studiens reproducerbarhet genomförs varje testfall flera gånger under identiska förutsättningar. Språkmodellen konfigureras med en fast temperaturinställning (temperature = 0) för att minimera stokastisk variation i output. Eftersom LLM:er fortfarande är probabilistiska system kan mindre variationer förekomma även vid låg temperatur, exempelvis beroende på modellversion eller underliggande hårdvaruimplementation.

Resultaten sammanställs med median och interkvartilavstånd (IQR), vilket är lämpligt vid mindre stickprov och minskar påverkan från enstaka avvikande resultat. Studien syftar dock inte till statistisk generalisering eller hypotestestning, utan till en designorienterad jämförelse mellan olika retrievalansatser i en kontrollerad experimentmiljö.

För att minimera påverkan från promptvariation används identiska promptar i samtliga retrievalsценарier under hela experimentet. Resultaten presenteras slutligen i tabeller och diagram för att möjliggöra transparens, jämförbarhet och tydlig analys av skillnader mellan retrievalmetoderna.

5.8 Genomförande

Studien genomförs i fem faser:

1. Problemförståelse och datainsamling
2. Etablering av baseline
3. Design och implementering av artefakt
4. Utvärdering
5. Analys och rapportering

Under arbetets gång sker kontinuerliga avstämningar med handledare och samarbetspartner, vilket stärker studiens relevans och kvalitet.

5.9 Metoddiskussion

Valet av en Design Science Research (DSR)-ansats bedöms vara lämpligt i relation till studiens syfte, eftersom fokus ligger på att utveckla och utvärdera en artefakt snarare än att enbart beskriva eller förklara ett fenomen (Hevner et al., 2004). Genom att kombinera artefaktutveckling med en jämförande utvärdering möjliggörs både ett praktiskt och analytiskt bidrag till forskningsområdet. Samtidigt innebär ansatsen flera metodologiska avvägningar, särskilt kopplade till kontroll, generaliserbarhet och tolkning av resultaten.

En central styrka i metodupplägget är den systematiska jämförelsen mellan olika retrievalsценарии. Genom att hålla testfall, promptar och språkmodell konstanta kan skillnader i resultat i högre grad relateras till retrievalmetoden snarare än till externa faktorer, vilket stödjer en isolerad bedömning av artefaktens bidrag (Oates, 2006). Att varje testfall genomförs flera gånger bidrar dessutom till att minska påverkan från slumpmässig variation i språkmodellens output, vilket är relevant eftersom LLM:er är probabilistiska system.

Samtidigt utgör studien inte ett fullt kontrollerat experiment. Trots standardiserade promptar och fasta modellinställningar kan variationer i språkmodellens beteende, tolkning av frågor och komplexiteten i datamaterialet påverka resultaten. Det innebär att observerade skillnader inte med full säkerhet kan tillskrivas retrievalmetoden ensam. Den interna validiteten bedöms därför som relativt stark, men inte fullständig.

Även konstruktvaliditeten är viktig att beakta, det vill säga i vilken utsträckning de valda mätmetoderna faktiskt mäter det som studien avser att undersöka (Yin, 2018). Begrepp som precision, kontextbevarande och tillförlitlighet operationaliseras genom mått såsom andel korrekta svar, recall och hallucinationsfrekvens. Dessa mått är etablerade inom forskning om informationshämtning och språkmodeller, men fångar främst kvantitativa aspekter av systemets prestanda. Kvalitativa dimensioner, exempelvis djupare semantisk förståelse eller relevans i komplexa sammanhang, kan därför vara svårare att mäta fullt ut.

Användningen av en fördefinierad ground truth möjliggör en mer strukturerad och reproducerbar jämförelse mellan retrievalsценарииerna. Samtidigt introducerar detta ett visst mått av subjektivitet, särskilt vid frågor där svar kräver tolkning eller sammanvägning av flera informationsobjekt. Även om tydliga bedömningskriterier används kan detta påverka reliabiliteten och möjligheten att uppnå identiska resultat vid en upprepad studie.

När det gäller extern validitet finns både styrkor och begränsningar. Studien genomförs på relationsbaserade och heterogena datamängder som liknar de informationsmiljöer där moderna retrievalssystem används i praktiken, vilket stärker studiens relevans och praktiska tillämpbarhet. Samtidigt är artefakten utvecklad och utvärderad inom en begränsad experimentmiljö, vilket innebär att resultaten inte automatiskt kan generaliseras till alla typer av databaser, domäner eller retrievalsценарии. Ytterligare studier i andra kontexter skulle därför behövas för att stärka generaliserbarheten.

Vidare bör valet av språkmodell och promptdesign ses som potentiella källor till bias. Eftersom språkmodellers output påverkas av både träningsdata och formulering av instruktioner kan delar av resultaten bero på faktorer som ligger utanför studiens kontroll. Detta är en etablerad utmaning inom forskning om LLM:er och behöver beaktas vid tolkning av resultaten.

Sammanfattningsvis innebär den valda metodansatsen en balans mellan kontroll och realism. En mer strikt experimentell design hade potentiellt kunnat stärka den interna validiteten ytterligare, men samtidigt minska studiens praktiska relevans. DSR-ansatsen möjliggör i stället utveckling och utvärdering av en konkret artefakt i en realistisk informationsmiljö, vilket ligger i linje med rekommendationer inom designorienterad forskning (Hevner et al., 2004; Peffers et al., 2007).

6. Systemdesign

Detta kapitel beskriver utformningen av den artefakt som utvecklas i studien. Artefakten utgörs av ett transformationslager som placeras mellan heterogent digitalt råmaterial och LLM-baserad analys. Utgångspunkten är att en språkmodell inte analyserar rådata direkt, utan analyserar en representation av materialet som skapats före modellinput. Systemdesignen fokuserar därför på hur råmaterial kan avgränsas, struktureras, beskrivas och göras spårbart innan det används som analysunderlag. Transformationslagret är utformat så att rådata bevaras oförändrad samtidigt som kompletterande strukturer skapas ovanpå materialet. Dessa strukturer består av filer, deterministiska textsegment, taggar, beskrivningar och relevansvärden, vilka lagras som en Neo4j-graf. Grafen fungerar som ett kontrollerat mellanled som möjliggör åtkomst, urval och kontextualisering inför analys.

6.1. Designgrund och mål

Designen utgår från studiens problemformulering och den teoretiska referensramen. Ett centralt antagande är att LLM-baserad analys av heterogent material i hög grad är beroende av hur materialet representeras innan det skickas till modellen. Problemet ligger därmed inte primärt i att en språkmodell hanterar olika filformat, utan i att råmaterial saknar en enhetlig och spårbar struktur för

åtkomst, urval och kontextualisering. Artefakten konstrueras som ett designsvar på detta problem, i linje med design science research där en artefakt utformas för att adressera ett identifierat och relevant problem (Hevner et al., 2004).

Designmålen för transformationslagret är:

1. att bevara råmaterialet oförändrat och hålla det fullständigt spårbart,
2. att skapa en enhetlig, maskinläsbar och navigerbar representation av materialet,
3. att möjliggöra urval av relevanta delar av materialet inför analys,
4. att reducera brus och minska andelen irrelevant input som når språkmodellen,
5. att hålla lagret tydligt avgränsat från både datainsamling och slutlig LLM-analys, så att dess effekt kan isoleras och utvärderas,
6. att begränsa artefaktens komplexitet till det som krävs för att pröva studiens hypotes.

6.2. Artefaktens avgränsning

Artefakten omfattar transformations- och indexeringslagret. Det inkluderar inläsning och klassificering av råmaterial, deterministisk segmentering, modellbaserad extraktion av taggar och beskrivningar på segmentnivå, sammanställning av filbeskrivningar, relevansviktning samt lagring i en grafdatabas.


Artefakten omfattar inte rådatainsamling som forskningsbidrag, även om materialet läses in från ett lokalt korpusarkiv. Den omfattar inte heller ett fullständigt produktionssystem, användarhantering, driftmiljö eller extern API-hosting. Den lokala workbench (Vite/React) som används i studien har dock en operativ koppling till Neo4j och LLM-leverantörer via webbläsaren och kör samma tjänstelogik som den headless-export som genererar utvärderingsdata; UI:t är därmed inte enbart en illustration. Inkluderat i artefakten är också steget embed-tags, som beräknar vektorer (intfloat/e5-small-v2) per tagg och facet och skapar vektorindex i Neo4j (tag_emb_topic, tag_emb_entities, tag_emb_activity, tag_emb_temporal, tag_emb_evidence samt tag_emb_all). Vid frågetillfälle embeddas prompt-taggar med samma modell och matchas mot dessa index (tagggrundning) — ett obligatoriskt steg för att den grafberikade hämtningsvägen ska kunna köras. Utanför scope: bild-OCR, separat chunk-vektorindex över hela segmenttext (endast tagg-vokabulär indexeras vektoriellt) samt produktionsdrift. Gränsen mot den efterföljande analysen är central för studien.

Transformationslagret använder språkmodeller som agenter för att berika

råmaterialet och därmed skapa en kontextuell väg till datan. Berikningen lagras som ett kompletterande lager ovanpå källmaterialet och består av segmentbeskrivningar, taggar inom de fem facetterna ämne (topic), entiteter (entities), aktivitet (activity), temporalitet (temporal) och evidens (evidence), samt relationer mellan dessa. Facetten lagras på HAS_TAG-relationen mellan segment och tagg, vilket möjliggör att samma taggnamn kan ha olika analytisk funktion beroende på kontext. Den efterföljande analysen, där en språkmodell använder denna berikade representation för att besvara frågor eller utföra analytiska uppgifter, sker däremot utanför själva transformationslagret och utgör det som jämförs mellan scenarier i utvärderingen.

6.3. Systemstruktur

Transformationslagret producerar en sökbar och spårbar mellanrepresentation som beskriver råmaterialet. Mellanrepresentationen utgör ett kompletterande lager ovanpå det och består av segment, beskrivningar, taggar, relevansvärden och relationer mellan dessa. Denna representation används för att välja ut och paketera relevant analysunderlag inför varje analysuppgift. Språkmodellen analyserar därefter ett serialiserat urval från representationen, inte rådata och inte grafstrukturen direkt.



Figur 1. Systemöversikt över den grafbaserade RAG-artefakten.

Transformationslagret (offline, gröna boxar) materialiserar HERB-korpusen i Neo4j genom segmentering, tvåpass-berikning, filnivåaggregering och vektorindexering. Frågehanteringen (online, lila boxar) tolkar användarfrågan, grundar dess taggar mot tag_emb-indexet, hämtar segment via viktade HAS_TAG-kanter under strukturell gate, och serialiserar resultatet till ett kontextpaket som skickas till språkmodellen. Grafen utgör den delade mellanrepresentationen — den skrivs en gång och läses vid varje fråga.

Systemet är uppbyggt som en pipeline där råmaterialet stegvis beskrivs och berikas genom transformationslagret, varpå urval ur den resulterande mellanrepresentationen serialiseras till ett kontextpaket som kan användas av en språkmodell. Pipeline-strukturen ger tydlig separation mellan databehandling, urval och analys, vilket är en förutsättning för att isolera transformationslagrets effekt. Övergripande består systemet av tre block: datakällor, transformationslager med tillhörande mellanrepresentation samt efterföljande LLM-baserad analys.

6.3.1. Datainput

Systemet tar emot heterogent digitalt material i en bredd av format, från strukturerade och semistrukturerade dataformat till ren text och dokument. Materialet kan vara strukturerat, semistrukturerat eller ostrukturerat. Vid initial bearbetning registreras varje fils format, storlek, identitet och tillhörighet till ett dataset. Material som inte kan ge textuella segment, exempelvis vissa bilder eller arkiv, registreras som filer men förs inte vidare till modellbaserad bearbetning.

6.3.2. Transformationslager

Transformationslagret består av tre huvudsakliga steg.

Segmentering. Varje fil delas upp deterministiskt enligt formatberoende regler. Determinismen gör processen reproducerbar och säkerställer att varje segment kan spåras tillbaka till sin fil, position och ordning.

Semantisk berikning. Steget extract körs per segment i två modellanrop. I det första anropet produceras en segmentbeskrivning (1–3 meningar) och en lista av taggsträngar utan facet-vikter; i det andra anropet bedöms varje rensad tagg på facet-nivå (0–1) i de fem dimensionerna topic, entities, activity, temporal och evidence. Ordningen är avsiktlig: genom att låta modellen först formulera en beskrivning och därefter göra facet-bedömningen aktiveras ett resonemangssteg som har visats förbättra utfallet i efterföljande uppgifter (Kojima et al., 2022; Wei et al., 2022) samtidigt som facet-poängsättningen får en stabilare grund än om allt skulle emitteras i ett enda anrop. Kantvikten w_{chunk} beräknas deterministiskt i kod från facet-vektorn (styrka gånger täckningsbonus); modellen emitterar inte w_{chunk} . För varje tagg skrivs en eller flera HAS_TAG-kanter (primär facet plus extra när $\text{facet} \geq 0,50$). Modellsvaren styrs av ett tvingat tool/schema (Anthropic) och valideras med Pydantic; fel loggas i errors.jsonl utan att tysta fortsätta (Beurer-Kellner et al., 2024; Willard & Louf, 2023).

Filnivåaggregering. Per fil körs därefter steget describe (en filsummering som syntetiseras från segmentbeskrivningarna) och steget score (jämförande relevance_to_file per segment inom filen, ett batched-anrop per fil). HERB-piloten skapar inte den äldre kanttypen (:File)-[:TAGGED]->(:Tag); retrieval läser HAS_TAG-kanter direkt på segmentnivå. Slutligen lyfter steget materialize strukturfält (product, section, channel, employee_id, years m.fl.) upp på :Chunk för hard gate, och steget embed-tags beräknar vektorer på :Tag-noder och skapar vektorindex tag_emb_<facet> . Resultatet av dessa steg utgör den berikade mellanrepresentation som beskrivs i 6.3.3.

6.3.3. Output till språkmodell

Efter transformationen finns materialet som en strukturerad och sökbar mellanrepresentation i grafen. Denna graf används inte direkt som input till språkmodellen. I stället fungerar grafen som ett indexerings- och urvalslager där relevanta filer, segment, taggar och metadata kan hämtas fram inför en analysuppgift.

När materialet ska användas av en språkmodell omvandlas det valda grafresultatet till ett promptkompatibelt format, exempelvis en strukturerad text- eller JSON-representation. Denna kan innehålla segmentinnehåll, segmentbeskrivningar, filbeskrivningar, taggar, kluster, relevansvikter och källhänvisningar. Outputen till språkmodellen är alltså inte grafen i sig, utan ett kontrollerat och serialiserat kontextpaket som genereras från grafen.

6.3.4. LLM-baserad analys

Den LLM-baserade analysen sker efter transformationslagret. Inför varje analysuppgift används grafen för att välja ut relevanta filer, segment och taggar, vilka serialiseras till ett promptkompatibelt kontextpaket enligt 6.3.3. Detta paket utgör underlaget för analysuppgifter såsom informationsutvinning, sammanfattning eller identifiering av relevanta entiteter. Resultatet från modellen utgör systemets slutliga output och är den storhet som jämförs mellan baseline och det transformerade scenariot i utvärderingen.

6.4. Designbeslut

Utformningen av transformationslagret vilar på ett antal centrala designbeslut, vilka fattats för att uppfylla designmålen och möjliggöra en systematisk utvärdering.

Modulär separation. Transformationslagret implementeras som ett separat och modulärt steg mellan rådata och språkmodellen. Detta möjliggör isolering av artefaktens funktion och en direkt jämförelse mot ett baseline-scenario.

Separationen är i linje med både pipeline-principer för dataintegration och design science, där modularitet underlättar både analys och vidareutveckling (Hevner et al., 2004).

Graf som mellanrepresentation. Den berikade representationen lagras i en grafdatabas i stället för i parallella filbaserade format. Motiveringen är att en graf direkt uttrycker de relationer mellan källor, filer, segment och taggar som agenterna producerar, och att den utgör ett naturligt underlag för urval och

spårbarhet inför en analysuppgift. Grafen utgör därmed ett indexerings- och urvalslager, inte ett promptformat. Den serialiseras till en text- eller JSON-baserad kontext först vid analystillfället.

Deterministisk segmentering. Segment genereras av regelbaserad logik, inte av en språkmodell. Skälen är reproducerbarhet, kostnadskontroll och möjligheten att jämföra körningar över tid. Språkmodellens roll begränsas därmed till tolkning och berikning, inte till att definiera datans grundläggande enheter.

Fem taggfacetter. Taggar bedöms i fem facetter — topic (ämne), entities (entiteter), activity (aktivitet), temporal (temporalitet) och evidence (evidens) — så att materialet kan beskrivas från flera analytiska perspektiv. Facettillhörigheten lagras på HAS_TAG-relationen mellan segment och tagg snarare än på själva taggnoden, eftersom samma taggnamn kan ha olika analytisk funktion beroende på kontext. Vid embed-tags-steget beräknas dessutom en separat vektor per facet (tag_emb_topic ... tag_emb_evidence) plus en sammanslagen tag_emb_all, vilket gör facet-nivån direkt användbar vid tagg-grundning under frågetolkning.

Tvåpassextraktion: beskrivning och taggsträngar, därefter facet-bedömning. Extraktionen sker i två modellanrop per segment: i det första produceras en beskrivning och en lista av taggsträngar; i det andra bedöms varje tagg på facet-nivå i de fem dimensionerna. Beskrivningssteget fungerar som ett resonemangssteg som lyfter kvaliteten på den efterföljande facet-bedömningen (Kojima et al., 2022; Wei et al., 2022). En alternativ utformning, där varje facet bearbetas av en separat agent utan första beskrivningssteget, skulle frikoppla bedömningen från segmentets fulla kontext och samtidigt öka kostnaden mångfaldigt utan motsvarande kvalitetsvinst.

Schemastyrda modellutdata. Modellens svar styrs av ett explicit schema, vilket gör utdata strukturellt förutsägbara och möjliga att validera mot grafens datamodell innan de skrivs. Detta minskar utrymmet för fria, svårtolkade utdata och gör transformationslagret kontrollerbart, felsökbart och utvärderingsbart (Beurer-Kellner et al., 2024; Willard & Louf, 2023).

Relevansviktning i stället för hård filtrering. I stället för att radera material som bedöms irrelevant reduceras brus genom att segment markeras som tomma där så är fallet och tilldelas relevansvärden i förhållande till sin fil. Detta bevarar fullständig spårbarhet bakåt mot råmaterialet och låter urvalet styras vid analystillfället, snarare än att binda artefakten till ett specifikt brusbegrepp.

Begränsad omfattning. Artefakten omfattar tagg-vektorindex (e5 på :Tag-noder) som obligatorisk del av den grafberikade hämtningsvägen, medan separata chunk-

vektorindex över hela segmenttext, bild-OCR, produktionsdrift och extern API-hosting ligger utanför artefaktens omfattning. Denna avgränsning gör designen tydligare kopplad till studiens syfte: att undersöka effekten av ett strukturerande transformationslager där grafkanter och tagg-vektorer kombineras för hämtning, inte där hela korpus indexeras två gånger.

Tydlig gränsdragning mot analysen. All analytisk uppgiftslösning sker i den efterföljande språkmodellen, inte i transformationslagret. Detta är centralt för att kunna isolera effekten av datatransformationen och därmed möjliggöra en rättvis jämförelse mellan scenarier.

6.5. Koppling till utvärderingen

Systemdesignen är utformad för att möjliggöra en kontrollerad och jämförbar utvärdering av artefaktens effekt. Genom att transformationslagret är tydligt separerat från både datakällor och den efterföljande analysen kan dess påverkan på modellens output isoleras.

Designen möjliggör en jämförelse mellan två scenarier:

1. *Baseline*: fulltextbaseline (Lucene) på rå segmenttext (Chunk.content) utan tagggraf, frågetolkning eller strukturell gate; resultatet serialiseras till samma typ av kontextpaket som används i det transformerade scenariot.
2. *Transformerat scenario*: frågetolkning, tagggrundning (e5 + kNN på taggvektorindex) och viktad HAS_TAG-retrieval under strukturell gate, serialiserat till ett kontextpaket som används som input till samma språkmodell som i baseline.

I båda scenarierna används samma modell, samma analysuppgift och jämförbara prompts. Det som skiljer scenarierna åt är vilken väg till datan som språkmodellen får tillgång till: i baseline-fallet ett osorterat råmaterial, i det transformerade fallet ett kontextualiserat och avgränsat urval byggt av agenternas berikning. Skillnader i resultat kan därmed kopplas till representationen av materialet snarare än till förändringar i modell eller prompt.

De delar av systemet som utvärderas är primärt:

- transformationslagrets effekt på den representation som når språkmodellen,
- hur denna förändring påverkar modellens output,
- skillnader i resultat mellan de två scenarierna.

Utvärderingen genomförs med kvantitativa mått, med särskilt fokus på:

- *tillförlitlighet* (korrekthet och konsistens i output),
- *precision* (andelen korrekt identifierad information),

- *effektivitet* (tokenförbrukning och svars längd),
- *spårbarhet* (möjlighet att härleda svaret till specifika segment, filer och taggar).

I det transformerade scenariot kan grafens struktur dessutom användas för att kontrollera exakt vilka segment, filer och taggar som låg till grund för analysen, vilket ger en form av kontroll över analysunderlaget som baseline-scenariot saknar. Kopplingen till RQ2 blir därmed att systemdesignen skapar en empiriskt testbar skillnad mellan rådata och en berikad representation av samma material: om det transformerade scenariot ger mer korrekta, fokuserade eller resurssnåla svar än baseline, tyder det på att transformationslagret bidrar med analytisk nytta.

7. Resultat

7.1 Översikt över genomförda tester

Utvärderingen följer upplägget i avsnitt 5.5. Underlaget består av 100 frågor med färdiga referenssvar (gold-frågor), hämtade från datasetets egen lista över besvarbara frågor. Frågorna ställdes mot en utvärderingskorpus (en Neo4j-databas med samma typ av material som i studien, men avgränsad för test) där vissa interna delar (oracle- och QA-sektioner) utelämnades så att modellen inte fick “facit” i förväg.

Samma svarsmodell (DeepSeek-chat, temperatur 0) användes i båda varianterna. Skillnaden ligger i hur kontext hämtas innan svaret skrivs:

Grafvarianten tolkar frågan, hittar relevanta taggar med semantisk likhet (modellen e5), och hämtar textsegment som är kopplade till dessa taggar i grafen. En strukturell gate (filter) begränsar vilka segment som får följa med, till exempel utifrån produkt, tidsperiod eller andra fält som frågan anger.

Fulltextvarianten (baseline) söker direkt i ett fulltextindex över segmentens rå text, på samma sätt som en klassisk nyckelordsökning i ett dokumentindex. Här finns ingen frågetolkning, inga taggar och ingen gate—bara de segment som sökningen rankar högst.

För att jämförelsen ska vara rättvis begränsades båda varianterna till högst 40 textsegment per fråga i huvudutvärderingen. Samma tak gällde när en separat modell (RAGAS-domaren) senare bedömde om svaren var grounded i det hämtade underlaget. Gränsen valdes innan huvudmätningen, som en fast evidensbudget, inte som “bästa k” efter att ha testat många värden på samma 100 frågor.

Kohort i huvudutvärderingen: 100 gold-frågor är definierade, men en fråga kunde inte köras i grafvarianten eftersom den kräver en medarbetar-identitet som saknas i utvärderingskorporus. 99 frågor ingår därför i huvudresultaten. På samtliga 99 gavs svar i båda varianterna.

Före huvudutvärderingen gjordes en kompletterande körning utan segmenttak (avsnitt 7.7). Den visade att hämtad text kunde bli mycket lång (i medeltal över hundra segment i grafvarianten), att svar-API ibland misslyckades på särskilt rörig chatttext, och att en ren “vem hämtar mest”-jämförelse utan tak blir otydlig.

Huvudtabellerna i detta kapitel bygger endast på den matchade 40-segmentskörningen.

7.2 Svarskorrekthet och trovärdighet (RAGAS)

Måttet `answer_correctness` kördes inte i denna studie. Trovärdighet operationaliseras därför med `faithfulness`, det vill säga andelen påståenden i svaret som RAGAS-judgen finner grundade i det presenterade kontextpaketet (tabell 1).

Arm	Andel besvarade i RAGAS n export	(faithfulness)	Faithfulness, median (IQR)
Baseline (Lucene)	95/100	94	0,80 (0,61–1,00)
Graf (tagg + gate)	92/100	92	0,81 (0,58–1,00)

Tabell 1. Exportkohort och RAGAS faithfulness (median, IQR).

Medianen för `faithfulness` skiljer sig endast marginellt (+0,01 till grafens fördel).

Baseline-armen producerade tre fler exporterade svar än grafen (95 mot 92).

7.3 Retrieval: recall och precision (RAGAS)

RAGAS-måtten `context_recall` och `context_precision` rapporteras per arm i tabell 2. `context_recall` bedömer hur stor andel av det refererade svaret som täcks av det hämtade kontextpaketet, medan `context_precision` mäter andelen relevant innehåll i samma paket.

Mått	Baseline (Lucene), median (IQR)	Graf (tagg + gate), median (IQR)	Δ (graf – baseline)
Context recall	1,00 (0,00–1,00)	0,86 (0,00–1,00)	–0,14
Context precision	0,00 (0,00–0,05)	0,00 (0,00–0,03)	≈ 0

Mått	Baseline (Lucene), median (IQR)	Graf (tagg + gate), median (IQR)	Δ (graf – baseline)
RAGAS n (context_recall)	95	91	—

Tabell 2. RAGAS context_recall och context_precision (median, IQR).

Baselinen har en högre median i context_recall: en fulltextsökning träffar ofta gold-evidensen direkt när referensen ligger lexikalt nära chunk-texten, medan grafarmen filtrerar bort segment via taggmatchningen och den strukturella gaten. context_precision nära noll i båda armarna avspeglar att kontextmängden är stor i förhållande till de specifika gold-utdragen och att LLM-judgen är strikt.

Huvudmått (median)	Baseline (Lucene)	Graf (tagg + gate)
Faithfulness	0,80	0,81
Context recall	1,00	0,86
Context precision	0,00	0,00

Tabell 3. Sammanfattning av huvudmått (median per stickprov).

Sammanfattningsvärdena bygger på median per stickprov, inte på det aritmetiska medelvärdet i .report.json overall-sektion.

7.4 Hallucinationsfrekvens

Hallucinationsfrekvens mäts i denna studie indirekt via RAGAS faithfulness (tabell 1 och 3). De fyra manuella hallucinationskategorierna som definieras i avsnitt 4.2 (fabricerade entiteter, felaktiga relationer, felaktiga attribut, icke-grundade inferenser) kvantifierades inte separat i den slutgiltiga pipelinen. Den separata kategoriseringen kvarstår således som ett öppet metodikspår snarare än ett ifyllt resultat.

7.5 Effektivitet och spårbarhet

Export-JSONL (ragas-export.ts) loggar per fråga meta.tokens (answer_in, answer_out), n_chunks, chunk_ids, gate och grounding. Kohortstatistik aggregerades från A_tags_k40.jsonl och B_baseline_k40.jsonl efter deduplicering per id; vid $k = 40$ var 99 frågor besvarade i båda armar.

Mått (median, IQR)	Graf (tagg + gate)	Baseline (Lucene)	Förhållande graf/baseline
Svarstokens in (meta.tokens.answer_in)	9 422 (4 832–14 818)	24 289 (23 074–26 090)	0,39
Hämtade segment (n_chunks)	15 (8–23)	40 (40–40)	0,38
Tecken i retrieved_contexts	45 499 (23 456–75 152)	132 948 (128 944–141 390)	0,34

Tabell 4. Svar-API och hämtad kontext vid $k = 40$ (median, IQR).

Baselinen fyller konsekvent taket $k = 40$, medan tagggrundningen och gaten ofta lämnar ett mindre antal segment (median 15). Vid likvärdig median faithfulness (avsnitt 7.2) använde grafarmen ungefär två femtedelar av baselines svarstokens in och en tredjedel av dess hämtade teckenmängd — det vill säga en avsevärt lägre LLM-ingång utan påvisad förlust i trovärdighet på det måttet, mot kostnaden av en lägre context recall (avsnitt 7.3).

Den ocappade piloten (bilaga) gav till jämförelse en mediansvarstokens in om cirka 75 000 i grafen mot 90 000 i baselinen (förhållande cirka 0,84) och en mediansegmentmängd om 122 mot 150. I det läget domineras kostnaden av stora kontextmängder och förekommande API-fel snarare än av skillnader mellan armarna.

Spårbarheten skiljer sig kvalitativt mellan armarna. Endast grafarmen exponerar tagg-härledning, gate och fil-id i export-metadatan, vilket gör det möjligt att härleda varje svar tillbaka till specifika segment, filer och taggar. Baseline-armen lagrar enbart Lucene-träffar utan facet- eller taggspår.

7.6 Sammanfattning av resultat

På 100 HERB gold-frågor är faithfulness i stort sett likvärdig mellan armarna (median 0,81 mot 0,80), context recall är högre för Lucene-baselinen (1,00 mot 0,86), och baselinen besvarar något fler frågor i exporten (95 mot 92). context_precision är låg i båda armarna. Vid $k = 40$ kombinerar grafarmen en lägre token- och segmentbudget (avsnitt 7.5) med en likvärdig faithfulness men en lägre context recall. Grafarmen prioriterar gate-styrd, tagggrundad selektion och spårbarhet; baseline maximerar lexikal recall mot gold-referensen. En universell graföverlägsenhet stöds inte av dessa data. Effektivitetsvinsten (cirka $0,39 \times$ svarstokens in) gäller HERB i kombination med herb-eval under matchad $k = 40$.

8. Analys/Diskussion

8.1. Inledning

Detta kapitel tolkar resultaten i kapitel 7 i förhållande till studiens forskningsfrågor, den teoretiska referensramen och designbesluten i kapitel 6. Eftersom resultatmönstret är blandat likvärdig trovärdighet, lägre context recall i grafen men väsentligt lägre token- och teckenförbrukning fokuserar analysen på att förklara varför dessa skillnader uppstår, snarare än att tolka in en entydig överlägsenhet för någondera arm.

8.2. Designens svar på RQ1

RQ1 frågade hur ett grafbaserat RAG-system kan designas för att stödja kontextbevarande hämtning från strukturerade databaser. Systemdesignen i kapitel 6 visar att detta är möjligt genom ett transformationslager som separerar deterministisk segmentering, tvåpass-extraktion av segmentbeskrivning och facet-taggar, materialisering av strukturfält på segmentnivå samt vektorindexering av tagg-vokabulären, och som lagrar resultatet som en navigerbar graf i Neo4j. Två designbeslut bedöms ha varit särskilt avgörande för utfallet. Det första är att grafen används som indexerings- och urvalslager, inte som direkt prompt-input. Det gör det möjligt att paketera ett kontrollerat och avgränsat kontextpaket inför varje analysuppgift, och är det som gör spårbarhet ner till segment och tagg möjlig (avsnitt 7.5). Det andra är att beskrivning och taggsträngar genereras i samma modellanrop, så att klassificeringen sker mot segmentets fulla kontext — ett resonemangssteg som är förenligt med tidigare fynd om att en formulerad förförståelse förbättrar efterföljande modellsteg (Kojima et al., 2022; Wei et al., 2022).

Designen utgör därmed en hybrid mellan grafbaserad och vektorbaserad RAG: grafen används för struktur, gate och spårbarhet, men själva semantiska matchningen sker via e5-vektorer på tagg-noder snarare än via multi-hop-traversal av grafen. På RQ1-nivå är artefakten därmed implementerbar och fungerande, och kontextbevarandet realiseras via taggar och strukturfält snarare än via rena traverseringar.

8.3. Tolkning av resultaten i förhållande till RQ2

RQ2 frågade vilken effekt grafbaserad hämtning har på (a) svarskorrekthet, (b) precision och (c) hallucinationsfrekvens. Tolkningen följer måtten i tabell 1–3. Svarskorrekthet och trovärdighet (RQ2a). Måttet `answer_correctness` kördes inte; trovärdighet operationaliseras därför via `faithfulness`. Medianen var i praktiken likvärdig mellan armarna (0,81 mot 0,80). Detta är ett centralt fynd: när grafarmen

reducerar kontextmängden till cirka en tredjedel av baseline (avsnitt 7.5) försvinner inte den uppmätta trovärdigheten. Med andra ord väljer gaten och tag grundningen inte bort den grundande evidensen i medianfallet, även om de väljer bort mycket annat material. En uppdelning per single-hop/multi-hop kan inte göras i nuvarande pipeline eftersom gold-mängden inte exponerar den dimensionen separat.

Precision och recall (RQ2b). Det tydligaste mönstret i tabell 2 är att baselinen har en högre median i context_recall (1,00 mot 0,86), medan context_precision är nära noll i båda armarna. Den höga baseline-recallen är en förväntad effekt av att gold-referenserna i HERB är lexikalt nära chunk-texten; en Lucene-sökning som returnerar 40 segment kommer i de flesta fall att inkludera den sträng som RAGAS-judgen eftersöker. Grafarmen väljer i stället ett mindre antal segment via tagggrundning och hard gate, vilket ökar risken att ett enskilt gold-utdrag inte ligger inom de hämtade segmenten även när relevant kontext finns i fler segment. Det låga context_precision-värdet i båda armarna speglar i sin tur att kontextpaketet är stort i förhållande till de specifika strängar som RAGAS-judgen jämför mot, snarare än att kontexten skulle vara irrelevant i sak.

Hallucinationsfrekvens (RQ2c). Eftersom de fyra manuella kategorierna i avsnitt 4.2 inte kvantifierades separat är det enda kvantitativa hallucinationsmåttet i studien faithfulness. På det måttet syns ingen tydlig skillnad mellan armarna. Det går därmed inte att, på basis av denna evaluering, hävda en allmän reduktion av hallucinationer genom grafbaserad hämtning — något som vore förenligt med Pan et al. (2024) men också med en mer skeptisk läsning av samma litteratur (Anh-Hoang et al., 2025). En skärpning av hallucinationsmätningen till de fyra kategorierna är en nödvändig förutsättning för att kunna differentiera effekten mellan armarna i framtida arbete.

8.4. Effektivitet, avvägningar och spårbarhet

Det mönster som tydligast skiljer armarna är effektivitet. Grafarmen använder i median cirka 39 % av baselines svarstokens in, cirka 38 % av antalet hämtade segment och cirka 34 % av tecknen i retrieved_contexts (tabell 4). Det är en betydande reduktion av LLM-ingången vid likvärdig trovärdighet.

Avvägningen mot detta är att grafarmen samtidigt har en lägre context recall. Ur ett produktionsperspektiv innebär det att grafarmens kontextpaket är mer selektivt det är billigare att skicka till modellen och lättare att verifiera manuellt men att det i en del frågor missar gold-evidens som fulltext-baselinen fångar genom att skicka mer. För enstaka frågor är transformationssteget en kostnad i form av extra urval och serialisering; i en produktionsmiljö där samma material återanvänds i många

analyser bör berikningen ses som en engångsinvestering vars värde fördelas över alla efterföljande modellanrop.

Spårbarheten är en kvalitativ skillnad som inte fångas av RAGAS-måtten. I grafarmen kan varje svar härledas till specifika segment, filer och taggar via export-meta, medan baselinen endast lagrar Lucene-träffar utan facet- eller taggspår. För praktiska tillämpningar i en journalistisk miljö som Bonnier News, där verifierbarhet är en yrkesetisk grundpremiss, är detta en distinktion som har värde även när kvantitativa kvalitetsmått är likvärdiga.

8.5. Resultaten i förhållande till tidigare forskning

Resultaten ger en mer nyanserad bild än den som ibland förmedlas i GraphRAG-litteraturen. De mätningar som finns här stödjer bestämt inte en universell överlägsenhet för grafbaserad hämtning över naiv fulltextretrieval, i alla fall inte på faithfulness eller context_recall i HERB-miljön. Den starkaste effekten ligger i stället i kontextreduktion vid bibehållen trovärdighet, vilket är förenligt med tidigare arbeten som betonar att strukturerad mellanrepresentation gör LLM-input mer effektiv och kontrollerbar (Edge et al., 2024; Peng et al., 2024).

Studien bidrar med tre observationer som nyanserar denna litteratur. För det första att en ocappad fulltext-baseline kan vara en mycket stark referenspunkt på recall-måttet vilket innebär att jämförelser måste matchas på en fast evidensbudget (här $k = 40$) för att vara informativa. För det andra att context_precision i RAGAS-judgen tenderar mot noll i båda armarna när kontextpaketet är stort — ett mått som därför bör tolkas med försiktighet i HERB-liknande miljöer. För det tredje att vinsten med tag grundning och gate först tydliggörs när kostnad och spårbarhet inkluderas i bedömningen, snarare än enbart kvalitetsmått.

Resultaten visar även att grafbaserad retrieval inte löser alla typer av hallucinationer eller relationsfel av sig själv; faithfulness-nivån är densamma för båda armarna på medianen. Detta bekräftar i sin tur den uppfattning som finns hos Peng et al. (2024) om att grafbaserad RAG i praktiken kompletterar snarare än ersätter andra mekanismer för att hantera modellens generativa beteende.

8.6. Begränsningar i tolkningen

Resultaten ska tolkas inom ramen för de metodologiska begränsningar som beskrivs i avsnitt 5.9. Stickprovet består av 100 gold-frågor hämtade från datasetets egna answerable_questions, utvärderingen är genomförd mot en specifik korpus (HERB) och en specifik eval-graf (herb-eval), och oracle- och QA-sektionerna är exkluderade. Det är därför inte möjligt att generalisera de exakta värdena till andra databaser eller domäner; den mer robusta slutsats som kan dras gäller riktningen i resultaten snarare än deras absoluta nivå.

Vidare påverkas resultaten av val av språkmodell (deepseek-chat, $T = 0$), av promptdesign och av RAGAS-judgens egen modell. Eftersom samma modell och prompt användes i båda armarna kan skillnaderna inte tillskrivas dessa faktorer, men den absoluta nivån på faithfulness och context-mått hade kunnat se annorlunda ut med en annan modell. En ytterligare begränsning är att studien inte kvantifierar hallucinationer enligt de fyra kategorierna i 4.2, vilket gör att frågan om vilka typer av hallucinationer som påverkas mest av grafbaserad hämtning förblir öppen.

9. Slutsats

Studiens syfte var att utveckla och utvärdera en grafbaserad RAG-artefakt för att hämta, representera och kontextualisera information från heterogena datakällor inför LLM-baserad analys. Genom Design Science Research konstruerades ett transformationslager som materialiserar HERB-korpusen i Neo4j, segmenterar råmaterialet deterministiskt, berikar segmenten med beskrivningar och taggar i fem facetter (topic, entities, activity, temporal, evidence) via tvåpass-extraktion, indexerar tagg-vokabulären vektoriellt (e5-small-v2) och möjliggör frågedriven hämtning via tag grundning och viktade HAS_TAG-kanter under en strukturell gate. Artefakten utvärderades i en kontrollerad jämförelse mot en fulltextbaseline (Lucene på rå segmenttext) på 100 gold-frågor hämtade från datasetets egen answerable_questions, med matchad evidensbudget $k = 40$.

På RQ1 visar studien att ett grafberikat RAG-system kan designas så att det stödjer kontextbevarande hämtning genom att tydligt separera (1) deterministisk segmentering och materialisering av strukturfält, (2) offline semantisk berikning via tvåpass-extraktion (segmentbeskrivning och taggsträngar i ett anrop, facetbedömning i ett andra), (3) vektorindexering av tagg-vokabulären och (4) analystids-urval där serialiserade segment inte rå graf skickas till språkmodellen. Designen utgör därmed en hybrid mellan grafbaserad och vektorbaserad RAG snarare än ren multi-hop-traversering.

På RQ2 ger mätningarna en blandad bild. Faithfulness är i praktiken likvärdig mellan armarna (median 0,81 mot 0,80), context_recall är högre för Lucene-baselines (1,00 mot 0,86) och context_precision är nära noll i båda armarna. De fyra hallucinationskategorierna i avsnitt 4.2 kvantifierades inte separat, och någon kategorispecifik effekt kan därför inte rapporteras. Den tydligaste skillnaden ligger i stället i resurs- och spårbarhetsdimensionen: grafarmen använder vid $k =$

40 i median cirka 39 % av baselines svarstokens in och cirka 34 % av dess teckenmängd i kontextpaketet, samtidigt som varje svar kan härledas till specifika segment, filer och taggar i exporten. Slutsatsen på RQ2 är därmed att grafbaserad hämtning, så som den implementeras här, inte är universellt överlägsen en ocappad fulltext-baseline på kvalitetsmått, men erbjuder en betydligt mer effektiv och spårbar väg till likvärdig trovärdighet.

Studiens praktiska bidrag är en designorienterad beskrivning av hur ett transformationslager kan byggas för att förbereda heterogent material inför LLM-baserad analys, samt en empirisk jämförelse som visar var en sådan ansats lönar sig (effektivitet, spårbarhet) och var den inte gör det (absolut recall mot lexikalt nära gold-evidens). För Bonnier News innebär detta en konkret startpunkt för fortsatt arbete med strukturerad informationsutvinning i en operativ miljö, där verifierbarhet och kontrollerad kontext är minst lika viktiga som råa kvalitetsmått. Det teoretiska bidraget är en nyansering av tidigare GraphRAG-litteratur genom att visa att skillnaden mot en stark fulltext-baseline kan ligga i kontexteffektivitet och spårbarhet snarare än i kvalitetsmåten i sig åtminstone i en miljö som HERB med matchad evidensbudget.

Framtida forskning bör undersöka hur artefakten beter sig på större och mer varierade datamängder, hur den interagerar med vektorbaserade hybridansatser, och hur valet av språkmodell påverkar effektens storlek. En tydlig metodologisk förbättring vore att kvantifiera de fyra hallucinationskategorierna i avsnitt 4.2 separat, så att frågan om var grafbaserad hämtning faktiskt reducerar hallucinationer kan besvaras finkornigare än via aggregerad faithfulness. En särskilt intressant fortsättning vore att utvärdera artefakten med fackpersoner på Bonnier News som bedömare, så att kvalitativa aspekter av svaren relevans i en journalistisk kontext, användbarhet i redaktionellt arbete kan komplettera de kvantitativa måtten som använts i denna studie.

Referenser

- Anh-Hoang, D., Tran, V., & Nguyen, L.-M. (2025). Survey and analysis of hallucinations in large language models: Attribution to prompting strategies or model behavior. *Frontiers in Artificial Intelligence*, 8, 1622292. <https://doi.org/10.3389/frai.2025.1622292>
- Brünnhäußer, J., Zhang, X., Konietzko, E. P., & Kehl, S. (2025). Automated Information Extraction from Unstructured Documents Using Large Language Models and different Questioning Strategies. *2025 5th International Conference on Electrical, Computer, Communications and Mechatronics Engineering (ICECCME)*, 1–6. <https://doi.org/10.1109/ICECCME64568.2025.11277979>
- Chen, B., Zhang, Z., Langrené, N., & Zhu, S. (2025). Unleashing the potential of prompt engineering for large language models. *Patterns*, 6(6), 101260. <https://doi.org/10.1016/j.patter.2025.101260>
- Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., & Liu, T. (2025). A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. *ACM Transactions on Information Systems*, 43(2), 1–55. <https://doi.org/10.1145/3703155>
- Lin, Z., Guan, S., Zhang, W., Zhang, H., Li, Y., & Zhang, H. (2024). Towards trustworthy LLMs: A review on debiasing and dehallucinating in large language models. *Artificial Intelligence Review*, 57(9), 243. <https://doi.org/10.1007/s10462-024-10896-y>
- Sahoo, P., Singh, A. K., Saha, S., Jain, V., Mondal, S., & Chadha, A. (2024). *A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications* (Version 2). arXiv. <https://doi.org/10.48550/ARXIV.2402.07927>
- Shrimal, A., Jain, A., Chowdhury, S., & Yenigalla, P. (2025). *PARSE: LLM Driven Schema Optimization for Reliable Entity Extraction* (Version 1). arXiv. <https://doi.org/10.48550/ARXIV.2510.08623>
- Sun, K., Huang, Y., Mehra, S., Kachuee, M., Chen, X., Tao, R., Lin, Z., Jessee, A., Shah, N., Betty, A., Liu, Y., Kumar, A., Yih, W., & Dong, X. L. (2025). *Knowledge Extraction on Semi-Structured Content: Does It Remain Relevant for Question Answering in the Era of LLMs?* (Version 1). arXiv. <https://doi.org/10.48550/ARXIV.2509.25107>
- Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). *Design Science in Information Systems Research*. MIS Quarterly.
- Peppers, K., Tuunanen, T., Rothenberger, M., & Chatterjee, S. (2007). *A Design Science Research Methodology*. Journal of Management Information Systems.
- Oates, B. J. (2006). *Researching Information Systems and Computing*.
- Kitchenham, B., & Charters, S. (2007). *Guidelines for performing Systematic Literature Reviews in Software Engineering*.
- Yin, R. K. (2018). *Case Study Research and Applications*.
- Kitchin, R. (2014). *The Data Revolution*.

Vetenskapsrådet (2017). *God forskningssed*.

Bilagor

7.1 Översikt över genomförda tester

Utvärderingen följer avsnitt 5.5 på 100 gold-frågor (ragas-questions.herb-gold100.jsonl) mot grafdatabasen herb-eval (oracle-/QA-sektioner exkluderade), med samma svarsmodell (deepseek-chat, T=0) och samma typ av serialiserat kontextpaket i två armar:

Grafberikad arm (A · tags): frågetolkning → e5-taggrundning (grounding_k = 20, minSim = 0,78) → viktad HAS_TAG-retrieval under strukturell gate.

Textbaseline (B · baseline): Lucene på index chunk_content_ft över rå Chunk.content, utan tolkning, taggar eller gate.

Primär körning: k = 40 segment per fråga på båda armarna; RAGAS-judge med --judge-max-contexts 40 och 1800 tecken per segment. k = 40 sattes före körning som fast evidensbudget (~40 × 1800 tecken), under pilotmedian (~120 segment/fråga vid ocappad graph-retrieval), med ändlig taggrundning — inte grid search på gold-100. Ocappad pilot (bilaga): limit = 0, grounding_k = 0 på graf; baseline topp 150; median ~120 segment och API-fel på Slack-tung text. Tabell 1–2 bygger på export/RAGAS 2026-05-20 (A_tags.report.json; baseline enligt ragas_eval_report.md).

Svarsgenerering före RAGAS (deduplicerad export, utan meta.error): graf 92/100, baseline 95/100. Permanent utebliven graf-fråga: gold_personalizeforce_34 (employee_id saknas i herb-eval). Övriga fel: JSON-body mot svar-API (Slack-text), oversized retrieval i pilot, enstaka judge-timeouts.

7.2 Svaskorrektthet och trovärdighet (RAGAS)

answer_correctness kördes inte. Trovärdighet operationaliseras med faithfulness (tabell 1).

Tabell 1. Exportkohort och RAGAS faithfulness (median, IQR).

Baseline (Lucene): Andel besvarade i export: 95/100. RAGAS n (faithfulness): 94. Faithfulness, median (IQR): 0,80 (0,61–1,00).

Graf (tagg + gate): Andel besvarade i export: 92/100. RAGAS n (faithfulness): 92. Faithfulness, median (IQR): 0,81 (0,58–1,00).

Median faithfulness skiljer marginellt (+0,01 till grafens fördel); baseline besvarade fler frågor i export (95 mot 92).

7.3 Retrieval: recall och precision (RAGAS)

Tabell 2. RAGAS context_recall och context_precision (median, IQR).

Context recall, median (IQR): Baseline (Lucene): 1,00 (0,00–1,00). Graf (tagg + gate): 0,86 (0,00–1,00). Δ (graf – baseline): –0,14.

Context precision, median (IQR): Baseline (Lucene): 0,00 (0,00–0,05). Graf (tagg + gate): 0,00 (0,00–0,03). Δ (graf – baseline): ≈ 0 .

RAGAS n (context_recall): Baseline: 95. Graf: 91.

Baseline hade högre median context_recall: fulltext träffar ofta gold-evidens när referensen är lexikalt nära chunk-text; graf-armen filtrerar via taggmatchning och gate. Context precision ≈ 0 i båda armarna speglar stora kontextmängder och strikt LLM-judge.

Tabell 3. Sammanfattning huvudmått (median).

Faithfulness: Baseline 0,80 | Graf 0,81. Context recall: Baseline 1,00 | Graf 0,86. Context precision: Baseline 0,00 | Graf 0,00.

Använd median per stickprov, inte aritmetiskt medel i .report.json overall.

7.4 Hallucinationsfrekvens

Hallucination mäts via RAGAS faithfulness (tabell 1–3). De fyra manuella kategorierna i avsnitt 4.2 kvantifierades inte separat i pipelinen.

7.5 Effektivitet och spårbarhet

Export-JSONL (ragas-export.ts) loggar per fråga meta.tokens (answer_in, answer_out), n_chunks, chunk_ids, gate och grounding. Kohortstatistik aggregerades från A_tags_k40.jsonl och B_baseline_k40.jsonl (dedupe per id; 99 besvarade i båda armarna vid $k = 40$).

Tabell 4. Svar-API och hämtad kontext vid $k = 40$ (median, IQR).

Svarstokens in (meta.tokens.answer_in): Graf: 9 422 (4 832–14 818). Baseline: 24 289 (23 074–26 090). Förhållande graf/baseline (medianer): 0,39.

Hämtade segment (n_chunks): Graf: 15 (8–23). Baseline: 40 (40–40). Förhållande: 0,38.

Tecken i retrieved_contexts (summa per fråga): Graf: 45 499 (23 456–75 152). Baseline: 132 948 (128 944–141 390). Förhållande: 0,34.

Baseline fyller konsekvent taket $k = 40$; tagggrundning och gate lämnar ofta färre segment (median 15). Vid likvärdig median faithfulness (§7.2) använde graf-armen ungefär två femtedelar av baseline svarstokens in och en tredjedel av hämtad teckenmängd — lägre LLM-ingång utan trovärdighetsförlust på det måttet, mot kostnaden lägre context recall (§7.3).

Ocappad pilot (bilaga): median answer_in $\sim 75k$ vs $\sim 90k$ (förhållande $\sim 0,84$), segment median 122 vs 150; stora kontextmängder och API-fel dominerar där.

Spårbarhet: endast graf-armen exponerar tagg-härledning, gate och fil-id i export-meta; baseline ger Lucene-träffar utan facet-/taggspår.

7.6 Sammanfattning av resultat

På 100 HERB gold-frågor: faithfulness i stort sett lika (median 0,81 vs 0,80), context recall högre för Lucene-baseline (1,00 vs 0,86), fler export-svar i export (95 vs 92), context precision låg i båda armarna. Vid $k = 40$ kombinerar graf-armen lägre token- och segmentbudget (§7.5) med likvärdig faithfulness men lägre context recall. Graf-armen prioriterar gate-styrd, tagggrundad selektion och spårbarhet; baseline maximerar lexikal recall mot gold-referens. Universell graföverlägsenhet stöds inte; effektivitetsvinsten ($\approx 0,39 \times$ svarstokens in) gäller HERB/herb-eval under matchad $k = 40$.

